

BÁO CÁO KỸ THUẬT
PHÂN TÍCH THỜI TIẾT VÀ CHẤT LƯỢNG
KHÔNG KHÍ
TP HỒ CHÍ MINH NĂM 2024

Môn: Lập trình xử lý dữ liệu

Nhóm: AIT2006-2-3.4

Tạ Duy Khánh 24022364

Nguyễn Đức Vũ Bảo 24022264

Đỗ Mạnh Quân 24022432

Năm dữ liệu: 2024

Ngày nộp: 19/12/2025

Commit Hash: 299a2da

Mục lục

1	Giới thiệu và Tổng quan dữ liệu	4
1.1	Mục tiêu dự án	4
1.2	Nguồn dữ liệu	4
1.2.1	Dữ liệu thời tiết	4
1.2.2	Dữ liệu chất lượng không khí	4
1.3	Đặc điểm chính của dữ liệu	5
2	Làm sạch và Chuẩn hoá dữ liệu	5
2.1	Quy tắc Quality Assurance (QA)	5
2.1.1	Dữ liệu thời tiết	5
2.1.2	Dữ liệu chất lượng không khí	6
2.2	Chuẩn hoá dữ liệu	6
2.2.1	Chuẩn hoá thời gian	6
2.2.2	Kết hợp dữ liệu (Merge)	7
3	Tổng hợp và Thống kê	7
3.1	Định nghĩa các chỉ số	7
3.1.1	Air Quality Index (AQI)	7
3.1.2	Normalized Index	8
3.2	Thống kê mô tả	8
3.2.1	Thống kê nhiệt độ	8
3.2.2	Thống kê PM2.5	9
4	Trực quan hoá	9
4.1	Chuỗi thời gian tổng hợp (Meteogram)	10
4.2	UV Index theo thời gian	11
4.3	Phân bố PM2.5	11
4.4	Xu hướng theo tháng	12
4.5	Ma trận tương quan	13
4.6	Mối quan hệ gió và PM2.5	14
4.7	Mối quan hệ nhiệt độ và Ozone	15
4.8	So sánh PM2.5 và PM10	16
4.9	Phân loại AQI	16
5	Các phân tích nâng cao	17
5.1	Dự báo PM2.5 ngày tiếp theo	17
5.1.1	Mục tiêu	17
5.1.2	Phương pháp	17
5.1.3	Phân tích dữ liệu	17
5.1.4	Kết quả dự báo	18
5.1.5	Đánh giá mô hình	19
5.1.6	Diễn giải kết quả	20
5.2	Phân cụm điều kiện môi trường (K-Means Clustering)	20
5.2.1	Mục tiêu	20
5.2.2	Phương pháp	20
5.2.3	Kết quả phân cụm	21

5.2.4	Trực quan hóa phân cụm	22
5.3	Phát hiện bất thường (Anomaly Detection)	23
5.3.1	Phương pháp	23
5.3.2	Case Study	23
6	Diễn giải và Kết luận	24
6.1	Phát hiện chính	24
6.2	Bối cảnh và ý nghĩa	25
6.3	Giới hạn của nghiên cứu	25
6.4	Đề xuất tiếp theo	25
7	Tài liệu tham khảo	26
7.1	Nguồn dữ liệu	26
7.2	Tiêu chuẩn và phương pháp	26
7.3	Thư viện Python	26
7.4	Phương pháp máy học	26
A	Cấu trúc thư mục dự án	27
B	Danh sách hình ảnh	28

1 Giới thiệu và Tổng quan dữ liệu

1.1 Mục tiêu dự án

Dự án này nhằm xử lý, phân tích và dự báo dữ liệu thời tiết và chất lượng không khí cho Thành phố Hồ Chí Minh trong năm 2024. Mục tiêu cụ thể bao gồm:

- Làm sạch và chuẩn hóa dữ liệu thời tiết và chất lượng không khí
- Tổng hợp thống kê theo nhiều khung thời gian (ngày, tuần, tháng)
- Phân tích xu hướng và mối quan hệ giữa các biến
- Dự báo nồng độ $PM_{2.5}$ cho ngày tiếp theo (tính năng nâng cao)
- Phân cụm các điều kiện môi trường theo đặc điểm thời tiết
- Phát hiện các ngày bất thường về chất lượng không khí

1.2 Nguồn dữ liệu

1.2.1 Dữ liệu thời tiết

- **Nguồn:** Meteostat (<https://meteostat.net>)
- **File:** meteostat_weather_data.csv
- **Phạm vi:** 1/1/2024 - 31/12/2024 (366 ngày)
- **Vị trí:** TP. Hồ Chí Minh (10.823°CN, 106.6296°CE)
- **Biến số:** Nhiệt độ, lượng mưa, tốc độ gió, hướng gió, áp suất khí quyển

1.2.2 Dữ liệu chất lượng không khí

- **Nguồn:** Open-Meteo Air Quality API (<https://open-meteo.com>)
- **File gốc:** open-meteo-hourly-AQ.csv (dữ liệu theo giờ)
- **File đã xử lý:** open-meteo-daily-AQ.csv (tổng hợp theo ngày)
- **Phạm vi:** 1/1/2024 - 31/12/2024 (366 ngày)
- **Vị trí:** Cùng tọa độ với dữ liệu thời tiết
- **Biến số:** $PM_{2.5}$, PM_{10} , CO, O_3 , CO_2 , UV Index

1.3 Đặc điểm chính của dữ liệu

Bảng 1 tổng hợp các đặc điểm chính của tập dữ liệu sau khi làm sạch và tổng hợp:

Bảng 1: Tổng quan dữ liệu năm 2024	
Đặc điểm	Giá trị
Vị trí	TP. Hồ Chí Minh
Tọa độ	10.823°CN, 106.6296°CE
Năm	2024
Tổng số ngày dữ liệu gốc	366 ngày
Số ngày sau QA (clean)	366 ngày
Tỷ lệ dữ liệu clean	100.00%
Số tuần	53 tuần
Số tháng	12 tháng
Nhiệt độ trung bình năm	29.10 °C
Tổng lượng mưa năm	1804.40 mm
Số ngày mưa trong năm	179 ngày
PM _{2.5} trung bình năm	22.67 $\mu\text{g}/\text{m}^3$
PM ₁₀ trung bình năm	32.32 $\mu\text{g}/\text{m}^3$
Số ngày PM _{2.5} vượt ngưỡng	132 ngày (36.1%)
Số ngày PM ₁₀ vượt ngưỡng	55 ngày (15.0%)
UV Index trung bình năm	8.83

2 Làm sạch và Chuẩn hoá dữ liệu

2.1 Quy tắc Quality Assurance (QA)

Dữ liệu được kiểm tra và làm sạch theo các quy tắc sau:

2.1.1 Dữ liệu thời tiết

Các vấn đề được phát hiện và xử lý trong dữ liệu thời tiết:

Bảng 2: Tóm tắt QA - Dữ liệu thời tiết			
Quy tắc	Số lỗi	Tỷ lệ	Hành động
Missing precipitation	12	3.28%	Gắn cờ <code>is_missing</code> , giữ nguyên NaN
Missing wind direction	366	100%	Gắn cờ <code>is_missing</code> , giữ nguyên NaN

Lưu ý: Hướng gió thiếu hoàn toàn (100%) do nguồn dữ liệu không cung cấp. Biến này không được sử dụng trong các phân tích tiếp theo.

2.1.2 Dữ liệu chất lượng không khí

Bảng 3: Tóm tắt QA - Dữ liệu chất lượng không khí

Quy tắc	Số lỗi	Tỷ lệ	Hành động
Missing CO ₂	299	81.69%	Gắn cờ <code>is_missing</code> , giữ nguyên NaN

Chiến lược xử lý:

- Giữ nguyên giá trị thiếu (NaN) thay vì imputation để tránh tạo bias
- Gắn cờ `is_missing` cho mỗi biến để tracking
- Loại bỏ biến CO₂ khỏi các phân tích do tỷ lệ thiếu quá cao
- Sử dụng các biến còn lại với độ đầy đủ dữ liệu > 95%

2.2 Chuẩn hoá dữ liệu

2.2.1 Chuẩn hoá thời gian

- Chuyển đổi tất cả timestamps sang định dạng YYYY-MM-DD
- Đồng bộ múi giờ UTC cho cả hai nguồn dữ liệu
- Tổng hợp dữ liệu hourly thành daily bằng hàm aggregation phù hợp:
 - Nhiệt độ, chất lượng không khí: **trung bình** (mean)
 - Lượng mưa: **tổng** (sum)
 - UV Index: **giá trị lớn nhất** (max)

2.2.2 Kết hợp dữ liệu (Merge)

Bảng 4: Thống kê quá trình merge dữ liệu

Chỉ số	Giá trị
Records thời tiết (input)	366
Records chất lượng không khí (input)	366
Records sau merge (output)	366
Records bị mất	0
Tỷ lệ thành công	100.00%
Phương pháp merge	INNER JOIN
Khung thời gian	01/01/2024 - 31/12/2024
Tổng số ngày	366 ngày
Số biến thời tiết	5
Số biến chất lượng không khí	6
Tổng biến dữ liệu	11
Tổng cột (bao gồm flags)	38
Records có vấn đề chất lượng	366
Records không có vấn đề	0
Độ đầy đủ dữ liệu tổng thể	83.18%

3 Tổng hợp và Thống kê

3.1 Định nghĩa các chỉ số

3.1.1 Air Quality Index (AQI)

AQI được tính dựa trên nồng độ $PM_{2.5}$ theo tiêu chuẩn US EPA:

$$AQI = \frac{I_{high} - I_{low}}{C_{high} - C_{low}} \times (C - C_{low}) + I_{low} \quad (1)$$

Trong đó:

- C : Nồng độ $PM_{2.5}$ đo được ($\mu g/m^3$)
- C_{low}, C_{high} : Ngưỡng nồng độ tương ứng với category
- I_{low}, I_{high} : Giá trị AQI tương ứng với category

Phân loại AQI:

- 0-50: Tốt (Good)
- 51-100: Trung bình (Moderate)
- 101-150: Không tốt cho nhóm nhạy cảm (Unhealthy for Sensitive Groups)
- 151-200: Không tốt (Unhealthy)

- 201-300: Rất không tốt (Very Unhealthy)
- 301+: Nguy hại (Hazardous)

3.1.2 Normalized Index

Index chuẩn hóa được tính cho từng biến:

$$\text{Normalized Index} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \times 100 \quad (2)$$

Trong đó:

- X : Giá trị hiện tại
- $X_{\min}, X_{\max}$: Giá trị min, max trong cả năm

3.2 Thống kê mô tả

Dữ liệu được tổng hợp theo 3 khung thời gian:

- **Daily:** Dữ liệu hàng ngày (366 records)
- **Weekly:** Tổng hợp theo tuần (53 records)
- **Monthly:** Tổng hợp theo tháng (12 records)

3.2.1 Thống kê nhiệt độ

Bảng 5: Thống kê nhiệt độ năm 2024

Chỉ số	Giá trị (°C)
Mean (Trung bình)	29.10
Median (Trung vị)	29.15
Std (Độ lệch chuẩn)	1.42
Min (Nhỏ nhất)	24.85
25th percentile	28.10
50th percentile (Median)	29.15
75th percentile	30.08
Max (Lớn nhất)	32.40

3.2.2 Thống kê PM_{2.5}

Bảng 6: Thống kê PM_{2.5} năm 2024


Chỉ số	Giá trị ($\mu\text{g}/\text{m}^3$)
Mean (Trung bình)	22.67
Median (Trung vị)	20.50
Std (Độ lệch chuẩn)	9.86
Min (Nhỏ nhất)	6.87
25th percentile	15.71
50th percentile (Median)	20.50
75th percentile	28.04
Max (Lớn nhất)	56.92
Số ngày vượt ngưỡng WHO ($15 \mu\text{g}/\text{m}^3$)	234 (63.9%)
Số ngày vượt ngưỡng US EPA ($35 \mu\text{g}/\text{m}^3$)	132 (36.1%)

4 Trực quan hoá

Các hình ảnh trực quan hóa được tạo ra để phân tích xu hướng và mối quan hệ giữa các biến. Tất cả các biểu đồ được lưu trong thư mục **figures/**.

4.1 Chuỗi thời gian tổng hợp (Meteogram)

HÌNH 1: Diễn biến Thời tiết & Chất lượng không khí (TP.HCM - 2024)




Hình 1: Meteogram hiển thị xu hướng đồng thời của nhiệt độ, lượng mưa, PM_{2.5}, và UV Index năm 2024.

Nhận xét:

- Meteogram cho phép quan sát mối quan hệ giữa các biến theo thời gian
- Nhiệt độ biến động nhẹ quanh 29°C với đỉnh vào tháng 4-5
- Lượng mưa tập trung vào mùa mưa (tháng 5-10)
- PM_{2.5} có xu hướng ngược với lượng mưa

4.2 UV Index theo thời gian

**HÌNH 2: Diễn biến Chỉ số tia cực tím (UV Index) trong năm
Tại TP.HCM (2024)**




Hình 2: Biến động UV Index năm 2024 với phân loại mức độ nguy hiểm.

Nhận xét:

- UV Index dao động trong khoảng 5-12, phần lớn ở mức High đến Very High
- Mức cao nhất tập trung vào tháng 4-5 (mùa khô)
- Giảm nhẹ trong mùa mưa do mây che nhiều

4.3 Phân bố PM2.5


**HÌNH 3: Phân bố tần suất nồng độ bụi PM2.5
Khu vực: TP.HCM (2024)**



Hình 3: Phân bố nồng độ PM_{2.5} năm 2024 với histogram và density plot.

Nhận xét:

- Phân bố lệch phải (right-skewed) với đuôi dài
- Phần lớn giá trị tập trung trong khoảng $15\text{--}30\text{ }\mu\text{g}/\text{m}^3$
- Có một số giá trị outliers vượt quá $50\text{ }\mu\text{g}/\text{m}^3$

4.4 Xu hướng theo tháng


Hình 4: Boxplot PM_{2.5} theo từng tháng năm 2024, cho thấy xu hướng theo mùa rõ rệt.

Nhận xét:

- Tháng 12, 1, 2, 3 có nồng độ PM_{2.5} cao nhất (mùa khô)
- Tháng 6, 7, 8 có nồng độ thấp nhất (mùa mưa)
- Tháng 11-12 có biến động lớn nhất (boxplot dài)

4.5 Ma trận tương quan

HÌNH 5: Ma trận tương quan (TP.HCM 2024)




Hình 5: Ma trận tương quan giữa các biến thời tiết và chất lượng không khí.

Mối tương quan chính:

- $PM_{2.5}$ và PM_{10} : tương quan dương mạnh (0.85+)
- $PM_{2.5}$ và lượng mưa: tương quan âm (-0.4 đến -0.5)
- Nhiệt độ và UV Index: tương quan dương
- Lượng mưa và O_3 : tương quan âm

4.6 Mối quan hệ gió và PM_{2.5}

**HÌNH 6: Tác động của Tốc độ gió đến nồng độ PM_{2.5}
Tại TP.HCM (2024)**




Hình 6: Scatter plot thể hiện mối quan hệ giữa tốc độ gió và nồng độ PM_{2.5}.

Nhận xét:

- Xu hướng tương quan âm nhẹ: gió mạnh giúp giảm PM_{2.5}
- Khi tốc độ gió < 10 km/h, PM_{2.5} có xu hướng cao và biến động lớn
- Gió > 15 km/h giúp khuếch tán bụi hiệu quả, PM_{2.5} thường < 30 $\mu\text{g}/\text{m}^3$

4.7 Mối quan hệ nhiệt độ và Ozone

**HÌNH 7: Mối liên hệ giữa Nhiệt độ và nồng độ Ozone (O_3)
Tại TP.HCM (2024)**




Hình 7: Scatter plot cho thấy mối quan hệ dương giữa nhiệt độ và nồng độ O_3 .

Nhận xét:

- Mối tương quan dương rõ rệt: nhiệt độ tăng làm tăng O_3
- Nguyên nhân: phản ứng quang hóa tạo O_3 diễn ra mạnh hơn ở nhiệt độ cao
- Nhiệt độ $> 30^\circ\text{C}$: O_3 thường $> 60 \mu\text{g}/\text{m}^3$

4.8 So sánh PM_{2.5} và PM₁₀




Hình 8: Time series so sánh xu hướng của PM_{2.5} và PM₁₀ qua thời gian.

Nhận xét:

- PM₁₀ luôn cao hơn PM_{2.5} (vì bao gồm cả PM_{2.5})
- Xu hướng biến động tương đồng nhau (correlation cao)
- Tỷ lệ PM_{2.5}/PM₁₀ trung bình khoảng 0.7 (70%)

4.9 Phân loại AQI



Hình 9: Phân bố các category AQI theo tháng năm 2024.

Nhận xét:

- Tháng 12, 1, 2: tỷ lệ "Unhealthy for Sensitive Groups" cao nhất
- Tháng 6, 7, 8: chủ yếu ở mức "Good" và "Moderate"
- Không có ngày nào đạt mức "Very Unhealthy" hoặc "Hazardous"

5 Các phân tích nâng cao

5.1 Dự báo PM_{2.5} ngày tiếp theo

5.1.1 Mục tiêu

Xây dựng mô hình dự báo nồng độ PM_{2.5} cho **ngày tiếp theo** dựa trên dữ liệu lịch sử và điều kiện thời tiết hiện tại.

5.1.2 Phương pháp

Model: Linear Regression


Features (15 biến):

1. **Lag features (3):** PM_{2.5} của 1, 2, 3 ngày trước
2. **Rolling averages (2):** Trung bình PM_{2.5} trong 3 ngày, 7 ngày
3. **Weather features (5):** Nhiệt độ, lượng mưa, tốc độ gió, áp suất, độ ẩm (của ngày hiện tại)
4. **Air quality features (3):** PM₁₀, O₃, CO (của ngày hiện tại)
5. **Temporal features (2):** Ngày trong tuần, tháng

Train/Test split:

- Training set: 280 ngày (80%)
- Test set: 70 ngày (20%)
- Phương pháp: Sequential split (giữ nguyên thứ tự thời gian)


5.1.3 Phân tích dữ liệu




Hình 10: Chuỗi thời gian PM_{2.5} năm 2024 - dữ liệu đầu vào cho mô hình dự báo.

Nhận xét về dữ liệu:

- $PM_{2.5}$ có xu hướng theo mùa: tăng vào mùa khô (tháng 1-3, 11-12)
- Giảm vào mùa mưa (tháng 5-9)
- Dao động mạnh trong ngắn hạn - cần lag features và rolling averages
- Có xu hướng tự tương quan (autocorrelation) mạnh

5.1.4 Kết quả dự báo

Hình 11: So sánh giá trị thực tế và dự báo $PM_{2.5}$ trên tập test. Scatter plot (trái) cho thấy mối tương quan; time series (phải) hiển thị dự báo theo thời gian.



Hình 12: Top 10 features quan trọng nhất trong mô hình dự báo PM_{2.5}. Các lag features và rolling averages có ảnh hưởng lớn nhất.

5.1.5 Đánh giá mô hình

Bảng 7: Kết quả dự báo PM_{2.5}

Dataset	Size	MAE	MAPE	RMSE	R ²
Training	280	3.41	16.84%	4.50	0.675
Test	70	8.36	32.71%	10.56	-0.284

Giải thích metrics:

- **MAE (Mean Absolute Error):** Sai số trung bình tuyệt đối ($\mu\text{g}/\text{m}^3$)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

- **MAPE (Mean Absolute Percentage Error):** Sai số phần trăm trung bình (%)

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (4)$$

- **RMSE (Root Mean Squared Error):** Căn bậc hai của sai số bình phương trung bình ($\mu\text{g}/\text{m}^3$)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5)$$

- **R^2 (Coefficient of Determination):** Hệ số xác định (0-1, càng cao càng tốt)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

5.1.6 Diễn giải kết quả

Hiệu suất trên Training set:

- $\text{MAE} = 3.41 \mu\text{g}/\text{m}^3$: Mô hình dự báo sai trung bình $3.41 \mu\text{g}/\text{m}^3$
- $\text{MAPE} = 16.84\%$: Sai số tương đối khoảng 17%
- $R^2 = 0.675$: Mô hình giải thích được 67.5% phương sai của $\text{PM}_{2.5}$

Hiệu suất trên Test set:

- $\text{MAE} = 8.36 \mu\text{g}/\text{m}^3$: Sai số tăng gấp 2.5 lần so với training
- $\text{MAPE} = 32.71\%$: Sai số tương đối tăng lên 33%
- $R^2 = -0.284$: Mô hình kém hơn việc dự báo bằng giá trị trung bình

Nguyên nhân overfitting:

- Chênh lệch lớn giữa training và test performance
- Model quá đơn giản (Linear Regression) không capture được non-linear patterns
- $\text{PM}_{2.5}$ chịu ảnh hưởng nhiều yếu tố ngoại sinh khó dự đoán
- Cần thử các model phức tạp hơn: Random Forest, XGBoost, LSTM

5.2 Phân cụm điều kiện môi trường (K-Means Clustering)

5.2.1 Mục tiêu

Nhóm các ngày có điều kiện môi trường tương tự nhau để phát hiện patterns và đặc điểm của từng nhóm.

5.2.2 Phương pháp

- **Algorithm:** K-Means Clustering
- **Số cụm (K):** 4 clusters
- **Features:** Nhiệt độ, lượng mưa, tốc độ gió, UV Index, $\text{PM}_{2.5}$, O_3
- **Preprocessing:** StandardScaler normalization

5.2.3 Kết quả phân cụm


Bảng 8: Đặc điểm các cụm điều kiện môi trường

Cụm	Ngày	Tỷ tr. (%)	Temp (°C)	Precip (mm)	Wind (km/h)	UV	PM2.5 ($\mu\text{g}/\text{m}^3$)	O3 ($\mu\text{g}/\text{m}^3$)
Mưa	59	16.7	28.06	16.63	13.84	7.59	20.62	41.03
Mưa-Bụi cao	94	26.6	28.17	5.98	8.19	7.31	30.47	45.46
Nóng-Sạch	119	33.6	30.69	1.38	13.09	10.78	15.99	56.71
Trung tính	82	23.2	28.86	1.17	8.97	8.79	25.54	72.03


Đặc điểm từng cụm:

1. **Cụm "Mưa" (59 ngày, 16.7%) - Màu vàng:** Lượng mưa cao nhất (16.63 mm/ngày), PM_{2.5} trung bình (20.62 $\mu\text{g}/\text{m}^3$), UV thấp do mây che
2. **Cụm "Mưa - Bụi cao" (94 ngày, 26.6%) - Màu tím:** PM_{2.5} cao nhất (30.47 $\mu\text{g}/\text{m}^3$), mưa vừa phải nhưng không đủ để giảm bụi, tốc độ gió thấp (8.19 km/h)
3. **Cụm "Nóng - Sạch" (119 ngày, 33.6%) - Màu đỏ:** Nhiệt độ cao nhất (30.69 °C), PM_{2.5} thấp nhất (15.99 $\mu\text{g}/\text{m}^3$), UV cao, gió mạnh
4. **Cụm "Trung tính/Giao mùa" (82 ngày, 23.2%) - Màu xanh xám:** Các chỉ số ở mức trung bình, O₃ cao nhất (72.03 $\mu\text{g}/\text{m}^3$)

5.2.4 Trực quan hóa phân cụm



Hình 13: Biểu đồ PCA scatter plot của 4 cụm điều kiện môi trường.



Hình 14: Calendar heatmap hiển thị phân bố các cụm theo ngày trong năm 2024.

Nhận xét từ calendar heatmap:

- Cụm "Nóng - Sạch" (đỏ) phổ biến nhất, xuất hiện nhiều vào mùa hè
- Cụm "Mưa - Bụi cao" (tím) tập trung vào đầu và cuối năm

- Cụm "Mưa"(vàng) xuất hiện chủ yếu trong mùa mưa (tháng 5-10)
- Cụm "Trung tính"(xanh xám) phân bố đều trong năm
- Phân bố cụm có tính thời vụ rõ rệt

5.3 Phát hiện bất thường (Anomaly Detection)


5.3.1 Phương pháp

Sử dụng **Isolation Forest** để phát hiện các ngày có chất lượng không khí bất thường:

- **Algorithm:** Isolation Forest
- **Contamination:** 5% (giả định 5% ngày là anomalies)
- **Features:** PM_{2.5}, lượng mưa, tốc độ gió, nhiệt độ
- **Kết quả:** Phát hiện được các ngày có ô nhiễm bất thường cao

5.3.2 Case Study

Phân tích chi tiết ngày có ô nhiễm cao:



Hình 15: Case Study Top 2: Diễn biến ô nhiễm ngày 23/11/2024 - một trong những ngày có PM_{2.5} cao nhất.

Ngày 23/11/2024 - Top 2 ngày ô nhiễm cao nhất:

- PM_{2.5}: 52.8 µg/m³ (vượt ngưỡng EPA 35 µg/m³)
- Tốc độ gió yếu: 7.2 km/h
- Lượng mưa: 0 mm (thời tiết khô hanh)
- Xu hướng: Tăng dần từ ngày 20/11, đỉnh điểm 23/11, sau đó giảm

Nhận xét chung về các ngày bất thường:

- Thường xảy ra vào cuối năm (tháng 11-12) - mùa khô
- Kết hợp giữa gió yếu (< 10 km/h) và không mưa
- $PM_{2.5}$ tăng dần trong 3-5 ngày, sau đó giảm khi có gió hoặc mưa
- Cần cảnh báo sớm khi xuất hiện dấu hiệu: gió yếu + khô hanh kéo dài

6 Diễn giải và Kết luận

6.1 Phát hiện chính

1. Chất lượng không khí TP.HCM năm 2024:

- $PM_{2.5}$ trung bình: $22.67 \mu g/m^3$ (cao hơn ngưỡng WHO: $15 \mu g/m^3$)
- 63.9% số ngày vượt ngưỡng WHO, 36.1% vượt ngưỡng US EPA
- Chất lượng không khí chưa đạt tiêu chuẩn quốc tế

2. Xu hướng theo mùa:

- $PM_{2.5}$ cao vào mùa khô (tháng 1-3, 11-12)
- $PM_{2.5}$ thấp vào mùa mưa (tháng 5-9)
- Lượng mưa có tác động tích cực đến chất lượng không khí

3. Mối quan hệ thời tiết - chất lượng không khí:

- Mưa giúp giảm $PM_{2.5}$, nhưng cần lượng mưa đủ lớn
- Gió mạnh giúp khuếch tán bụi hiệu quả
- Nhiệt độ cao kết hợp với gió mạnh tạo điều kiện tốt cho không khí sạch

4. Phân cụm môi trường:

- Xác định được 4 loại điều kiện môi trường đặc trưng
- Cụm "Nóng - Sạch" chiếm tỷ trọng lớn nhất (33.6%)
- Cụm "Mưa - Bụi cao" là trường hợp đáng chú ý (26.6%)

5. Khả năng dự báo $PM_{2.5}$:

- Linear Regression cho kết quả chấp nhận được trên training set
- Overfitting trên test set cho thấy cần model phức tạp hơn
- Lag features và rolling averages là predictors quan trọng nhất

6.2 Bối cảnh và ý nghĩa

Kết quả phân tích cho thấy chất lượng không khí TP.HCM năm 2024 chưa đạt tiêu chuẩn của WHO, với hơn 60% số ngày có $PM_{2.5}$ vượt ngưỡng an toàn. Điều này đặt ra thách thức cho sức khỏe cộng đồng, đặc biệt là nhóm nhạy cảm (trẻ em, người cao tuổi, người có bệnh hô hấp).

Mối quan hệ giữa thời tiết và chất lượng không khí được xác nhận rõ ràng: mùa mưa giúp cải thiện chất lượng không khí đáng kể, trong khi mùa khô có xu hướng tích tụ bụi. Phát hiện này có thể hỗ trợ hoạch định chính sách quản lý chất lượng không khí theo mùa.

Phân cụm K-Means đã giúp nhận diện 4 loại điều kiện môi trường đặc trưng, trong đó cụm "Mưa - Bụi cao" cần được quan tâm đặc biệt vì kết hợp giữa điều kiện thời tiết không thuận lợi và ô nhiễm cao.

6.3 Giới hạn của nghiên cứu

1. Dữ liệu:

- Chỉ có dữ liệu của 1 năm (2024), chưa đủ để phân tích xu hướng dài hạn
- Thiếu một số biến quan trọng (hướng gió, CO_2)
- Dữ liệu tại 1 điểm, chưa đại diện cho toàn TP.HCM

2. Mô hình dự báo:

- Linear Regression quá đơn giản, không capture được non-linear patterns
- Overfitting trên test set
- Chưa xem xét yếu tố ngoại sinh (giao thông, công nghiệp, cháy rừng)

3. Phương pháp:

- Chưa áp dụng kỹ thuật feature selection
- Chưa thử các thuật toán advanced (ensemble methods, deep learning)
- Chưa có cross-validation để đánh giá robustness

6.4 Đề xuất tiếp theo

1. Mở rộng dữ liệu:

- Thu thập dữ liệu nhiều năm để phân tích xu hướng dài hạn
- Thêm nhiều điểm đo tại các quận/huyện khác nhau
- Tích hợp dữ liệu về giao thông, hoạt động công nghiệp

2. Cải thiện mô hình dự báo:

- Thử các model phức tạp: Random Forest, XGBoost, LSTM
- Áp dụng feature engineering nâng cao
- Implement ensemble methods để kết hợp nhiều models

3. Phân tích sâu hơn:

- Phân tích tác động của các sự kiện đặc biệt (lễ, tết, lockdown)
- Nghiên cứu correlation giữa $PM_{2.5}$ và các chỉ số sức khỏe cộng đồng
- Xây dựng hệ thống cảnh báo sớm cho ngày có chất lượng không khí xấu

4. Ứng dụng thực tế:

- Xây dựng dashboard real-time monitoring
- Tích hợp với hệ thống dự báo thời tiết để tư vấn cho người dân
- Hỗ trợ hoạch định chính sách quản lý chất lượng không khí

7 Tài liệu tham khảo

7.1 Nguồn dữ liệu

1. Meteostat - Weather and Climate Data. <https://meteostat.net>
2. Open-Meteo Air Quality API. <https://open-meteo.com/en/docs/air-quality-api>

7.2 Tiêu chuẩn và phương pháp

1. World Health Organization (WHO). WHO Global Air Quality Guidelines, 2021.
2. U.S. Environmental Protection Agency (EPA). Air Quality Index (AQI) Technical Assistance Document.
3. U.S. EPA. AirNow.gov - Air Quality Index Calculator. <https://www.airnow.gov/aqi/aqi-calculator/>

7.3 Thư viện Python

1. Pandas (v2.x) - Data manipulation and analysis. <https://pandas.pydata.org>
2. NumPy (v1.x) - Numerical computing. <https://numpy.org>
3. Matplotlib (v3.x) - Data visualization. <https://matplotlib.org>
4. Seaborn (v0.x) - Statistical data visualization. <https://seaborn.pydata.org>
5. Scikit-learn (v1.x) - Machine learning. <https://scikit-learn.org>
6. Meteostat Python Library. <https://dev.meteostat.net/python/>

7.4 Phương pháp máy học

1. Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, pp. 2825-2830.
2. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.

A Cấu trúc thư mục dự án

```

2526-LTXLDL-PROJECT-AIT2006-2-3.4/
|-- raw/                                # Du lieu goc
|   |-- meteostat_weather_data.csv
|   +-- open-meteo-hourly-AQ.csv
|
|-- processed/                          # Du lieu da xu ly
|   |-- weather_cleaned.csv
|   |-- airquality_cleaned.csv
|   |-- final_combined_data.csv
|   +-- [aggregated files...]
|
|-- reports/                            # Bao cao va ket qua
|   |-- qa_weather_summary.csv
|   |-- qa_airquality_summary.csv
|   |-- statistics_summary.csv
|   +-- pm25_forecasting_results.csv
|
|-- figures/                            # Hinh anh (16 figures)
|   |-- 01_time_series.pdf
|   |-- 02_uv_index.pdf
|   |-- 03_Pm25_distribution.pdf
|   |-- 04_monthly_boxplot.pdf
|   |-- 05_correlation_matrix.pdf
|   |-- 06_wind_pm25_scatter.pdf
|   |-- 7_temp_ozone_scatter.pdf
|   |-- 8_pm25_vs_pm10_timeseries.pdf
|   |-- 09_aqi_category_stacked_bar.pdf
|   |-- 10_kmeans_pca_scatter_yellow_rain.pdf
|   |-- 11_kmeans_calendar_heatmap_yellow.pdf
|   |-- 12_feature_importance.pdf
|   |-- 13_pm25_predictions.pdf
|   |-- 14_timeseries_pm25.pdf
|   +-- 15_case_study_rank2_2024-11-23.pdf
|
+-- src/                                # Ma nguon
    |-- 01_weather_data_cleaning.ipynb
    |-- 02_airquality_data_cleaning.ipynb
    |-- 03_merge_and_sync.ipynb
    |-- 04_statistics_and_aggregation.ipynb
    |-- 05_visualization.ipynb
    |-- 06_pm25_forecasting.ipynb
    |-- 07_advanced_analysis.ipynb
    +-- 08_kmeans_clustering.ipynb

```

B Danh sách hình ảnh

Bảng 9: Danh sách 15 figures được sử dụng trong báo cáo

STT	Tên file	Mô tả
1	01_time_series.pdf	Meteogram tổng hợp
2	02_uv_index.pdf	UV Index theo thời gian
3	03_Pm25_distribution.pdf	Phân bố PM2.5
4	04_monthly_boxplot.pdf	Boxplot theo tháng
5	05_correlation_matrix.pdf	Ma trận tương quan
6	06_wind_pm25_scatter.pdf	Scatter gió vs PM2.5
7	7_temp_ozone_scatter.pdf	Scatter nhiệt độ vs O3
8	8_pm25_vs_pm10_timeseries.pdf	So sánh PM2.5 và PM10
9	09_aqi_category_stacked_bar.pdf	Phân loại AQI
10	10_kmeans_pca_scatter_yellow_rain.pdf	PCA scatter clustering
11	11_kmeans_calendar_heatmap_yellow.pdf	Calendar heatmap
12	12_feature_importance.pdf	Feature importance
13	13_pm25_predictions.pdf	Kết quả dự báo
14	14_timeseries_pm25.pdf	Time series PM2.5
15	15_case_study_rank2_2024-11-23.pdf	Case study Top 2